

KKBOX 인공지능 데이터 전처리 결과서

시점 누출을 방지한 고객 단위 피처 마트 구축과 최종 학습 데이터 검증

992,931명

예측 대상 고객

392,106,543
행

스캔한 이용 로그

57개

최종 입력 피처

0건

최종 결측 중복

보고서 목적

원본 KKBOX 데이터가 어떤 기준과 규칙으로 정제·집계·병합되어 LightGBM Enhanced v2의 입력 데이터가 되었는지 재현 가능한 수준으로 기록한다.

작성 기준: preprocessing/01~08 및 modeling/04 노트북의 저장된 실행 결과

관측 종료일: 2017-01-31 | 최종 테이블: model_table_enhanced_v2.csv

1. 결과 요약

전처리의 핵심은 단순 정제가 아니라 예측 시점에 알 수 있는 정보만 남기는 것이었다.

44열

기본 모델 테이블

61열

Enhanced v2 전체

57개

모델 입력 피쳐

12.81%

로그 미보유 고객

구분	최종 결과	검증 근거
예측 단위	고객(msno) 1명당 1행	992,931행 / msno 중복 0
관측 기준	2017-01-31까지의 회원·거래·로그	snapshot 단일값 확인
타깃	멤버십 만료 후 30일 내 유효 재구독이 없으면 is_churn=1	train.csv 라벨 사용
분할	고객 기준 Stratified 70/15/15	split 간 고객 중복 0
결측 처리	의미상 0 / 명시적 범주 / Train 중앙값	최종 결측 0
대용량 처리	user_logs 1,000만행 청크 집계	392,106,543행 완주
최종 산출물	model_table_enhanced_v2.csv	992,931행 × 61열

핵심 통제

검증·테스트 데이터의 통계량을 이용하지 않도록 수치형 결측 대체값은 Train split에서만 계산하고 Valid/Test에는 동일 값을 적용했다.

2. 예측 문제와 시점 누출 방지

KKBOX의 타깃 정의와 데이터 제공 기간을 분리해 실제 개입 가능한 조기 예측 문제로 재구성했다.

KKBOX 이탈은 현재 멤버십 만료 후 30일 이내 새로운 유효 구독 거래가 없는 경우로 정의된다. 원본 transactions.csv와 user_logs.csv는 2017-02-28까지의 기록을 포함하므로 그대로 사용하면 2월 만료 고객의 결과 결정 과정이 피처에 포함될 수 있다.

구간	기간	사용 여부	역할
관측 구간	~ 2017-01-31	사용	회원·결제·이용 행동 피처 생성
만료 코호트	2017년 2월 중심	예측 대상	992,931명의 고객 라벨
결과 확인	만료일 이후 30일	피처에서 제외	is_churn 결정

진단 지표	초기 방식	2017-01-31 재설계	해석
days_to_expire 단변량 Directional AUC	0.905	0.590	결과에 가까운 정보가 제거되며 비정상적으로 강한 신호 완화

결정

모든 날짜 기반 필터와 파생 피처의 기준일을 2017-01-31로 통일하고, 이후 거래·로그를 전처리 단계에서 제거했다.

이 결정으로 성능 수치는 낮아졌지만, 모델이 실제 운영 시점에 사용할 수 있는 정보만 학습하도록 문제 정의가 바로잡혔다.

3. 원천 데이터와 처리 범위

라벨 고객을 중심으로 회원·거래·로그 테이블을 Left Join하는 구조다.

원천	핵심 컬럼	처리 규모	전처리 목적
train.csv	msno, is_churn	992,931명	예측 대상과 타깃 정의
members.csv	city, bd, gender, registered_via, registration_init_time	6,769,473행	회원 속성·가입 기간 생성
transactions.csv	결제수단, 요금제, 금액, 자동갱신, 거래일, 만료일, 취소	중복 제거 후 21,544,407행	결제 이력·최근 상태 집계
user_logs.csv	date, 재생 구간별 곡 수, num_unq, total_secs	392,106,543행	7·30·90일 및 전체 이용 행동 집계

라벨 고객이 기준 테이블이므로 회원·거래·로그가 없는 고객도 제거하지 않았다. 소스 부재 여부를 별도 플래그로 보존하고 Left Join하여 예측 대상 992,931명을 유지했다.

소스 존재 플래그	존재 비율	의미
has_member_record	88.34%	회원 정보 매칭 여부
has_transaction_record	99.79%	관측 종료일까지 거래 존재 여부
has_log_activity	87.19%	관측 종료일까지 이용 로그 존재 여부

주의

전체 원천 테이블 행 수와 최종 라벨 고객 수는 다르다. 230만 거래 사용자와 510만 로그 사용자는 원천 집계 대상이며, 최종 학습 테이블은 train.csv의 992,931명으로 제한된다.

4. 전체 전처리 흐름과 산출물

01~08 노트북의 실행 순서와 파일 의존성을 고정했다.

단계	처리	산출물	규모
01	라벨·Split	labels_pooled.csv / user_split.csv	992,931행
02	회원 피처	features_members.csv	6,769,473행
03	거래 피처	features_transactions.csv	2,330,992행
04	이용 로그 피처	features_user_logs.csv	5,106,101행
05	고객 기준 Left Join	model_table.csv	992,931행 × 41열
06	결측 대체·존재 플래그	model_table_final.csv	992,931행 × 44열
07	품질·누출 검증	검증 결과	결측·중복 0
04 모델링	Enhanced v1 파생 피처	model_table_enhanced_v1.csv	+16개 피처
08	최근 로그 경과일	model_table_enhanced_v2.csv	992,931행 × 61열

실행 원칙

각 단계는 앞 단계의 저장 파일을 읽고 동일 경로에 재생성한다. CSV 저장은 기본적으로 덮어쓰기이며, 04의 로그 집계는 컷오프가 포함된 캐시 파일명을 사용한다.

5. 라벨 코호트와 데이터 분할

고객 ID 단위로 분리하여 동일 고객이 Train·Valid·Test에 동시에 나타나지 않도록 했다.

695,051	148,940	148,940	6.39%
Train	Validation	Test	전체 이탈률

Split	고객 수	이탈률	역할
Train	695,051	6.3923%	모델 학습·중앙값 계산
Validation	148,940	6.3925%	모델 선택·임계값 결정
Test	148,940	6.3918%	최종 일반화 성능 평가

- train_test_split에 is_churn stratify와 random_state=42를 적용했다.
- Train과 임시 집합을 70/30으로 나눈 뒤 임시 집합을 Valid/Test 15/15로 분리했다.
- 세 split의 msno 교집합이 모두 0인지 assert로 검증했다.
- labels_pooled.csv의 snapshot은 모든 행에서 2017-01-31로 저장했다.

불균형 대응

전처리 단계에서는 SMOTE로 행을 복제하지 않았다. 원본 고객 분포를 유지하고 stratified split으로 동일한 이탈률을 보존했으며, 모델 평가에서는 PR-AUC를 핵심 지표로 사용했다.

6. 회원 데이터 전처리

회원 정보는 정적 속성과 가입 기간으로 변환하되 통계 기반 대체는 병합 이후 Train에서만 수행했다.

원본	처리 규칙	출력 피쳐
city	코드값 유지, 미매칭 시 -999	city
registered_via	코드값 유지, 미매칭 시 -999	registered_via
bd	0 이하 또는 100 초과를 이상치로 마킹	bd_clean, bd_is_missing
gender	결측을 unknown 범주로 명시	gender
registration_init_time	2017-01-31과의 일수 차이 계산	tenure_days

6,769,473

회원 원천 행

4,545,866

bd 이상치-결측

67.2%

bd 비정상 비율

6개

회원 입력 피쳐

나이 이상치는 즉시 중앙값으로 채우지 않고 NaN으로 남긴 뒤 bd_is_missing=1을 함께 생성했다. 중앙값은 전체 회원이 아니라 최종 Train 고객에서 계산해 Valid/Test 정보 유입을 차단했다.

해석상 장점

bd_is_missing은 단순 결측 표시가 아니라 회원 프로필 작성 성향을 나타낼 수 있다. 값 대체와 결측 여부를 동시에 제공해 정보 손실을 줄였다.

7. 거래 데이터 전처리

결제 이력은 고객 전체 이력의 집계와 마지막 거래 시점의 상태로 나누어 구성했다.

3,339	1,371	21,544,407	2,330,992
완전 중복 제거	비정상 만료일	정제 후 거래 행	거래 보유 고객

구분	피쳐	정의
이력 규모	txn_count, payment_method_nunique, plan_days_nunique	거래 수와 결제·요금제 다양성
갱신·취소	auto_renew_rate, cancel_count, cancel_rate	자동갱신과 취소 행동
금액	total_amount_paid, avg_discount	누적 결제액과 평균 할인
최근 거래	last_payment_plan_days, last_plan_list_price, last_actual_amount_paid	마지막 거래의 요금제·금액
최근 상태	last_is_auto_renew, days_since_last_txn, days_to_expire	자동갱신 여부와 기준일 대비 날짜 차이

- transaction_date가 2017-01-31 이하인 거래만 사용했다.
- membership_expire_date가 2010-01-01 이전이면 1970 센티넬 등 비정상값으로 보고 결측 처리했다.
- 마지막 거래 동점은 transaction_date → membership_expire_date → actual_amount_paid 순으로 결정했다.
- days_since_last_txn = 2017-01-31 - 마지막 거래일, days_to_expire = 마지막 만료일 - 2017-01-31로 계산했다.

8. 대용량 이용 로그 전처리

392,106,543행을 메모리에 한 번에 올리지 않고 청크별 부분 집계 후 고객 단위로 합산했다.

392.1M	10M	5,106,101	20.7분
전체 스캔 행	기본 청크 크기	집계 사용자	저장 실행 기준

처리 항목	규칙
날짜 필터	date ≤ 2017-01-31만 유지
기간 버킷	0~6일, 7~14일, 15~29일, 30~89일, 90일 이상
재생 수	num_25 + num_50 + num_75 + num_985 + num_100
재생시간 이상치	0초 이상 172,800초(48시간) 이하만 평균 계산에 사용
완주율	num_100 / 전체 재생 수
청크 병합	msno × 기간 버킷별 합계를 누적한 뒤 최종 피쳐 계산

각 기간창(d7, d30, d90, full)마다 active_days, avg_num_unq, avg_total_secs, completion_rate를 생성하고, 최근 15일과 이전 15일의 재생시간 변화를 trend_secs_recent15_vs_prior15로 계산했다.

메모리 안정성

원본 로그를 청크 단위로 읽고 필요한 컬럼·기간만 남긴 뒤 즉시 집계했다. 컷오프별 캐시(user_logs_features_cache_20170131.pkl)를 분리해 재실행 비용과 잘못된 캐시 재사용 위험을 줄였다.

9. 병합과 결측치 처리

값이 없는 이유를 구분한 뒤 의미에 맞는 세 가지 대체 규칙을 적용했다.

결측 유형	대상 예시	처리
소스 자체가 없음	txn_count, active_days, total_amount_paid	의미상 0으로 대체 + 존재 플래그 보존
범주 정보 없음	city, registered_via, gender	-999 또는 unknown 명시 범주
통계적 수치 결측	평균·비율·최근 거래·나이	Train split 중앙값으로 대체

0 대체 컬럼	이유
txn_count, payment_method_nunique, plan_days_nunique, cancel_count, total_amount_paid	거래 기록이 없으면 횟수·합계가 0이라는 의미가 자연스러움
d7/d30/d90/full_active_days	로그 기록이 없으면 관측 활동일이 0

누출 방지

중앙값 계산은 table[split == 'train']만 사용했다. Validation과 Test에는 Train에서 저장한 impute_values.json의 값을 적용했다.

41열

병합 직후

+3

존재 플래그

44열

결측 처리 후

0건

최종 결측

10. 고도화 파생 피처

단순 누적값에서 최근 행동 변화·결제 안정성·만료 정합성을 표현하는 피처로 확장했다.

영역	추가 피처	의미
활동률	active_rate_7/30/90	기간 대비 실제 활동일 비율
활동 변화	activity_change_7_30, activity_change_30_90	최근 이용 빈도의 증가·감소
이용 강도	secs_ratio_7_30, uniq_ratio_7_30, completion_change_7_30	재생시간·고유곡·완주율 변화
결제	avg_amount_per_txn, last_discount_rate	거래당 결제액과 최근 할인율
만료 정합성	expiry_alignment_gap, expiry_alignment_abs_gap, remaining_plan_ratio	요금제 일수와 만료일까지 남은 기간의 일치 정도
장기 관계	txn_per_tenure_month	가입 기간 대비 거래 빈도
갱신 행동	auto_renew_change, auto_cancel_interaction	최근 자동갱신 변화와 자동갱신·취소 결합

Enhanced v1에서 16개 파생 피처를 추가했다. 모든 비율 계산은 0으로 나누는 경우를 안전하게 처리하고, 계산 결과의 무한값을 제거했다.

설계 의도

고객의 절대 이용량뿐 아니라 '최근 7일이 평소 30·90일보다 얼마나 변했는가'를 표현하여 이탈 직전의 행동 변화를 포착하도록 했다.

11. 최근 로그 경과일 고도화

최종 이용일의 recency를 별도 청크 집계해 Enhanced v2에 추가했다.

392,106,543	233,541,013	865,735	127,196
스캔 행	대상 고객 로그	로그 보유 고객	로그 미보유 고객

단계	처리
대상 제한	labels_pooled.csv의 992,931명과 date ≤ 2017-01-31 조건 동시 적용
청크 집계	500만행 단위로 고객별 최대 로그 날짜를 누적
피처 계산	days_since_last_log = 2017-01-31 - last_log_date
로그 없음	has_log_activity=0으로 보존하고 사전 정의한 대체값 사용
병합	Enhanced v1에 days_since_last_log만 추가

검증	결과
recency_features	992,931행 × 4열
로그 미보유 비율	12.81%
실제 경과일 범위	0~761일
단변량 Directional AUC	0.513228

단변량 AUC는 약하지만 다른 활동·결제 피처와의 상호작용으로 최종 검증 PR-AUC 개선에 기여했으므로 v2에 채택했다.

12. 최종 57개 입력 피처 구성

61개 전체 열에서 식별자·관측일·타깃·split을 제외한 57개를 모델에 입력했다.

그룹	개수	피처
회원	6	city, registered_via, bd_clean, bd_is_missing, gender, tenure_days
거래	14	txn_count, payment_method_nunique, plan_days_nunique, auto_renew_rate, cancel_count, cancel_rate, total_amount_paid, avg_discount, last_payment_plan_days, last_plan_list_price, last_actual_amount_paid, last_is_auto_renew, days_since_last_txn, days_to_expire
이용 로그	17	d7/d30/d90/full별 active_days-avg_num_unq-avg_total_secs-completion_rate, trend_secs_recent15_vs_prior15
소스 존재	3	has_member_record, has_transaction_record, has_log_activity
Enhanced v1	16	활동률·활동 변화·이용 강도·결제·만료 적합성·갱신 행동 파생 피처
Enhanced v2	1	days_since_last_log
합계	57	LightGBM Enhanced v2 입력 피처

제외 열

msno는 식별자, snapshot은 관측 기준일, is_churn은 타깃, split은 데이터 분할 정보이므로 모델 입력에서 제외했다.

범주형	수치형
city, registered_via, gender	나머지 54개 피처
LightGBM category dtype 사용	결측 처리 완료 후 원래 단위 유지

13. 최종 품질 검증

학습 전에 행 수준 무결성, 시점, 분할, 결측, 피처 범위를 assert와 요약 통계로 확인했다.

992,931	61	0	0
최종 행	전체 열	결측치	msno 중복

검증 항목	결과	판정
전체 행·열	992,931 × 61	통과
고객 고유성	msno 중복 0	통과
결측	전체 결측 0	통과
관측일	전 행 2017-01-31	통과
Split	695,051 / 148,940 / 148,940	통과
이탈률	각 split 6.39%	통과
최근 거래 경과일	음수 0	통과
최근 로그 경과일	음수 0, 실제값 0~761	통과

만료 상태	고객 수	비율	이탈률
관측일 이전·당일 만료	14,366	1.45%	51.55%
2월 만료	887,749	89.41%	5.83%
3월 이후 만료	90,816	9.15%	4.71%

만료일이 과거인 행은 자동 삭제하지 않았다. 이는 거래 기록의 누락·비정상 만료 상태·복귀 가능성을 포함할 수 있어 모델과 세그먼트에서 상태 정보로 다루고, 서비스에서는 장기 만료 고객을 Win-back으로 분리했다.

14. 재현 절차와 통제 사항

전처리 산출물은 아래 순서로 다시 생성할 수 있다.

순서	노트북	핵심 산출물
1	01_train_valid_test_split.ipynb	labels_pooled.csv, user_split.csv
2	02_members_features.ipynb	features_members.csv
3	03_transactions_features.ipynb	features_transactions.csv
4	04_user_logs_features.ipynb	features_user_logs.csv, cutoff 캐시
5	05_merge_final_table.ipynb	model_table.csv
6	06_impute_features.ipynb	model_table_final.csv, impute_values.json
7	07_preprocessing_check.ipynb	품질 검증
8	modeling/04_feature_engineering.ipynb	model_table_enhanced_v1.csv
9	08_user_log_recency_enhancement.ipynb	model_table_enhanced_v2.csv

- 노트북은 번호 순서대로 실행하며 data/raw 원본 파일이 필요하다.
- 04와 08은 전체 user_logs를 스캔하므로 가장 오래 걸리고 충분한 디스크 공간이 필요하다.
- 컷오프 날짜를 바꾸면 기존 로그 캐시를 재사용하지 않고 새 캐시를 생성해야 한다.
- 전처리 CSV는 대용량이므로 Git에 포함하지 않고 재현 환경에서 생성한다.
- 모델 배포 시 feature_cols 순서와 범주형 dtype을 metajson과 동일하게 유지해야 한다.

버전 관리

코드·결과서·최종 모델·메타데이터는 GitHub에 저장하고, 대용량 원본 및 중간 CSV는 .gitignore로 제외한다.

15. 한계와 개선 계획

현재 전처리는 단일 관측 스냅샷의 배치 예측에 최적화되어 있다.

현재 한계	영향	개선 방향
단일 2017-01-31 스냅샷	시간 변화 일반화 확인 제한	월별 동적 스냅샷 생성
랜덤 Stratified split	미래 기간 성능을 직접 보장하지 않음	train_v2를 활용한 Time-out validation
고객 단위 집계	로그 순서와 단기 패턴 일부 손실	일·주 단위 시계열 피쳐 또는 sequence 모델
결측 중앙값 대체	분포의 복잡한 구조 단순화	모델별 native missing 처리 비교
과거 만료 고객 포함	일부 데이터 품질 이슈 가능	긴급 갱신·Win-back을 분리해 평가

결론

최종 전처리 데이터는 시점 누출을 통제하고, 고객 단위 고유성·분할 무결성·결측 제거를 검증한 57개 피쳐의 학습 입력이다. 향후에는 동일 규칙으로 여러 관측월을 생성해 시간 외 검증과 시계열 고도화를 수행한다.

근거 파일

- preprocessing/01_train_valid_test_split.ipynb ~ 08_user_log_recency_enhancement.ipynb
- modeling/04_feature_engineering.ipynb
- models/lightgbm_enhanced_v2_meta.json
- README.md 및 docs/KKBOX_프로젝트_통합문서.md