

인공지능 학습 결과서

KKBOX 구독 이탈 예측 · LightGBM Enhanced v2

최종 결과

Test PR-AUC 0.583427 · ROC-AUC 0.903563 · F1 0.556735

문서 구분	인공지능 학습 결과서
문제 유형	정형 데이터 기반 이진 분류
최종 모델	LightGBM Enhanced v2
관측 종료일	2017-01-31
타겟	멤버십 만료 후 30일 이내 유효 재구독이 없는 고객
모델 파일	models/lightgbm_enhanced_v2.txt

본 문서는 저장된 모델 메타데이터, 모델링 노트북의 실행 결과 및 최종 테스트 평가값을 기준으로 작성했습니다.

01. 요약

모델 선정 근거와 실무 활용 기준

핵심 결론

이탈률 6.39%의 불균형 데이터에서 PR-AUC를 주 지표로 비교한 결과, LightGBM Enhanced v2가 MLP와 다른 머신러닝 모델보다 높은 이탈 고객 선별력을 보여 최종 모델로 선정되었습니다.

구분	결과	해석
최종 모델	LightGBM Enhanced v2	표 형태의 결제·이용 피처와 비선형 상호작용에 적합
입력	57개 피처	회원·거래·이용 로그와 파생변수
주 지표	Test PR-AUC 0.583427	무작위 기준선 0.0639 대비 높은 양성 선별력
보조 지표	ROC-AUC 0.903563	전체 고객의 순위 판별력이 높음
운영 임계값	0.270839	Validation F1 최대 지점에서 결정
상위 5%	Precision 61.06%	고비용 집중 케어 후보군
상위 10%	Recall 67.86%	저비용 리마인드 확장 후보군

모델의 목적은 고객을 확정적으로 이탈 고객으로 판정하는 것이 아니라, 한정된 마케팅 자원을 배분할 우선순위를 만드는 것입니다.

02. 비즈니스 문제와 타겟 정의

라벨·관측 시점·캠페인 의사결정의 기준

이탈 정의

라벨	2017년 2월 멤버십 만료 고객 중 현재 멤버십 만료일로부터 30일 이내에 새로운 유효 구독 거래가 없으면 is_churn=1로 정의합니다.
-----------	---

예측 시점

- 피처 관측 종료일: 2017-01-31
- 타겟 평가: 2월 만료 이후 30일 재구독 여부
- 2월 이후 거래·로그는 입력 피처에 포함하지 않음

타겟팅 가정

운영 범위	권장 액션	근거
위험도 상위 5%	개인화 상담·고가치 혜택	Precision 61.06%, Lift 9.55배
위험도 상위 10%	앱 알림·갱신 리마인드	Recall 67.86%, Lift 6.79배
임계값 이상	일반 Retention 후보	Validation F1 균형 기준

비용·효익 원칙

실제 캠페인 비용과 유지 성공률이 제공되지 않았으므로 임의의 금액을 성과로 제시하지 않습니다. 운영 단계에서는 이탈확률 × 유지 성공률 × 고객가치 - 캠페인 비용으로 기대효익을 계산하고, 양수인 고객을 우선 대상으로 선정합니다.

03. 데이터 구성과 분할

고객 단위 중복을 방지한 Stratified 70/15/15

세트	고객 수	비율	이탈률	사용 목적
Train	695,051	70%	6.3923%	모델 학습
Validation	148,940	15%	6.3925%	모델 임계값 선택
Test	148,940	15%	6.3918%	최종 1회 평가
전체	992,931	100%	6.3923%	2월 만료 예측 코호트

분할 원칙

- msno 기준 고객 1명당 한 행이며 고객 중복이 없습니다.
- is_churn을 기준으로 계층화하여 세 세트의 이탈률을 동일하게 유지했습니다.
- 단일 2월 만료 코호트라는 데이터 제약으로 시간 분할 대신 사용자 단위 랜덤 분할을 적용했습니다.
- Test 결과 확인 이후 추가 튜닝에는 Test를 사용하지 않는 것을 원칙으로 합니다.

불균형

잔존 929,460명, 이탈 63,471명으로 약 14.64:1입니다. 모두 잔존으로 예측해도 Accuracy 93.61%가 나오므로 Accuracy를 핵심 지표로 사용하지 않았습니다.

04. 누수 통제와 입력 피쳐

2017-01-31 이전에 관측 가능한 정보만 사용

통제 항목	처리	이유
is_churn	입력에서 제거	예측 대상 라벨
msno	식별자로만 사용	고객 식별값은 일반화 가능한 행동 피쳐가 아님
split	입력에서 제거	데이터 분할 표식
snapshot	입력에서 제거	관측 기준 관리용 메타 정보
2월 이후 거래·로그	집계에서 제외	타깃 결정 기간의 미래 정보 누수 방지
train_v2	사용하지 않음	3월 코호트 및 3월까지 갱신된 데이터 혼입 방지

최종 57개 피쳐 그룹

그룹	예시	개수
회원	city, registered_via, bd_clean, tenure_days	6
거래	txn_count, auto_renew_rate, total_amount_paid	14
이용 로그	d7/d30/d90/full 활동·청취·완곡률	17
관측 여부	has_member_record, has_transaction_record, has_log_activity	3
고도화 파생변수	활동 변화, 결제 패턴, 만료 정합성, 로그 최근성	17

05. 평가 지표와 선택 이유

불균형 분류와 캠페인 타겟팅을 함께 평가

지표	역할	본 프로젝트에서의 의미
PR-AUC	주 지표	이탈 고객 비율이 낮을 때 이탈 후보의 정밀도·재현율을 종합
ROC-AUC	순위 지표	임계값과 무관한 전체 고객의 위험 순위 판별력
Precision	비용 관점	캠페인 대상 중 실제 이탈 고객의 비율
Recall	손실 관점	실제 이탈 고객 중 모델이 발견한 비율
F1	균형 지표	Precision과 Recall의 조화평균이며 운영 임계값 선정에 사용
Precision@K	타겟팅 지표	상위 K% 고객에게 캠페인할 때의 적중률
Recall@K	커버리지 지표	상위 K%가 전체 이탈 고객을 얼마나 포함하는지 평가
Lift@K	효율 지표	무작위 타겟팅 대비 이탈 고객 집중 정도

선택 원칙

모델 비교에는 PR-AUC, 운영 임계값에는 Validation F1, 실제 캠페인 규모 결정에는 Precision@K·Recall@K·Lift@K를 사용합니다.

06. 실험 설계


동일 분할과 동일 평가 기준으로 모델을 비교

실험	전처리·피쳐	주요 설정	선택 목적
LightGBM Baseline	기본 40개 피쳐	Binary, seed 42	강한 표 데이터 기준선
LightGBM Optuna	기본 피쳐	TPE seed 42	하이퍼파라미터 탐색
Enhanced v1	행동·결제 파생변수	PR-AUC 조기 종료	도메인 피쳐 효과 확인
Enhanced v2	v1 + days_since_last_log	312 iteration	최종 모델
XGBoost	동일 문제 피쳐	random_state 42	부스팅 모델 비교
CatBoost	범주형 포함	random_seed 42	범주형 부스팅 비교
Random Forest	원-핫 피쳐	random_state 42	배경 기준선
Logistic Regression	스케일-원-핫	random_state 42	선형 기준선
MLP	68개 스케일-원-핫	PyTorch seed 고정	딥러닝 비교

모든 모델은 동일한 사용자 분할을 사용했습니다. 범주형 처리 방식과 모델별 입력 표현은 알고리즘 특성에 맞게 구성했습니다.

07. 머신러닝 비교 결과

Validation PR-AUC 기준 모델 순위



모델	Validation PR-AUC	해석
LightGBM Optuna	0.5736	가장 높은 선별력과 빠른 학습
XGBoost	0.5623	부스팅 계열의 경쟁력 확인
CatBoost	0.5616	범주형 처리 강점
Random Forest	0.5213	부스팅보다 낮은 성능
Logistic Regression	0.4042	복잡한 비선형 관계 포착 한계

08. LightGBM 고도화 과정

Baseline에서 Enhanced v2까지의 개선 스토리

단계	Validation PR-AUC	변화	핵심 개선
Baseline	0.5726	-	기본 회원·거래·로그 집계
Optuna	0.5736	+0.0010	하이퍼파라미터 탐색
Enhanced v1	0.5825	+0.0089	행동 변화·결제·만료 정합성 파생변수
Enhanced v2	0.5836	+0.0011	최근 로그 경과일 추가 및 최종 재학습

고도화 피처 예시

피처	설명	기대 효과
activity_change_7_30	7일과 30일 활동을 변화	최근 급격한 이용 감소 감지
expiry_alignment_gap	관측 만료일과 결제 이력 정합성	갱신·만료 패턴 표현
remaining_plan_ratio	남은 이용기간과 플랜 기간 비율	생명주기 위치 표준화
auto_renew_change	최근 자동갱신과 과거 비율의 차이	갱신 설정 변화 감지
days_since_last_log	마지막 이용 로그 후 경과일	최근 서비스 이탈 조짐 보완

09. 딥러닝 비교

동일 문제에서 MLP와 최종 LightGBM 비교

모델	Test ROC-AUC	Test PR-AUC	Precision	Recall	F1
MLP Baseline	0.8941	0.5513	0.5405	0.5382	0.5394
MLP Tuned	0.8924	0.5599	0.5351	0.5527	0.5438
LightGBM Enhanced v2	0.9036	0.5834	0.5368	0.5783	0.5567

선택 결과

LightGBM Enhanced v2는 MLP Tuned보다 Test PR-AUC가 약 0.0235 높았습니다. 정형 데이터 적합성, 학습 효율, SHAP 해석 가능성, 서빙 편의성을 함께 고려해 최종 모델로 채택했습니다.

MLP 구성

- 입력: 수치형 스케일링 + 범주형 원-핫 인코딩, 총 68개
- 모델: 17,537개 학습 파라미터의 다층 퍼셉트론
- 손실함수: BCEWithLogitsLoss, Optimizer: AdamW
- 튜닝: 클래스 가중치 설정을 비교하고 Validation PR-AUC로 모델 선택

10. 최종 모델 성능

독립 Test 세트 148,940명 평가

지표	값	설명
ROC-AUC	0.903563	전체 고객 순위 판별력
PR-AUC	0.583427	이탈 고객 선별 주 지표
LogLoss	0.143026	확률 예측의 손실
Precision	0.536759	예측 이탈 고객 중 실제 이탈 비율
Recall	0.578256	실제 이탈 고객 중 발견 비율
F1	0.556735	Precision-Recall 균형
Threshold	0.270839	Validation F1 최대 기준

Confusion Matrix

실제 / 예측	잔존(0)	이탈(1)
잔존(0)	TN 134,669	FP 4,751
이탈(1)	FN 4,015	TP 5,505

Test 이탈 고객 9,520명 중 5,505명을 찾아냈고, 4,015명을 놓쳤습니다. 따라서 예측 점수는 확정 판정이 아니라 캠페인 우선순위로 사용해야 합니다.

11. 임계값과 Top-K 타겟팅

운영 목적에 따라 대상 규모와 비용을 조절

전략	선택 고객	Precision	Recall	Lift	권장 활용
상위 5%	7,447	61.06%	47.76%	9.55배	상당·고가치 혜택
상위 10%	14,894	43.37%	67.86%	6.79배	리마인드·저비용 혜택
F1 임계값	10,256	53.68%	57.83%	8.40배	균형 운영 기준

운영 선택 기준

- 캠페인 단가가 높으면 Precision이 높은 상위 5%를 우선합니다.
- 이탈 고객 누락 손실이 크면 Recall이 높은 상위 10%까지 확장합니다.
- 대상 수 제한이 없다면 Validation F1 임계값을 기본 기준으로 사용합니다.
- 실제 비용·전환율이 확보되면 기대효익 최대화 임계값으로 재설정해야 합니다.

12. 설명가능성 분석

SHAP과 모델 중요도로 주요 이탈 신호를 해석

순위	주요 변수	해석
1	last_is_auto_renew	최근 거래의 자동갱신 여부가 가장 강한 신호
2	expiry_alignment_gap	만료일과 거래 이력의 정합성 차이
3	auto_renew_rate	과거 거래에서 자동갱신을 유지한 비율
4	total_amount_paid	누적 결제 규모와 고객 생명주기
5	days_to_expire	관측일 기준 만료까지 남은 기간
6	days_since_last_txn	마지막 결제 후 경과일
7	d90_active_days	최근 90일 이용 지속성
8	txn_count	전체 거래 횟수
9	days_since_last_log	마지막 서비스 이용 후 경과일
10	tenure_days	가입 이후 경과 기간

해석 주의

SHAP과 중요도는 예측 근거와 변수의 연관성을 설명하지만, 특정 마케팅 액션의 인과 효과를 증명하지 않습니다. 혜택 효과는 향후 전환 데이터나 온라인 A/B 테스트로 검증해야 합니다.

13. 최종 학습 설정

저장된 메타데이터 기준

파라미터	값	파라미터	값
objective	binary	metric	average_precision
seed	42	verbose	-1
feature_pre_filter	False	num_leaves	236
max_depth	11	learning_rate	0.01598387174722713
min_child_samples	28	feature_fraction	0.8724506684766818
bagging_fraction	0.8933899425966071	bagging_freq	9
lambda_l1	9.078375852198261e-07	lambda_l2	3.4339210234101867e-06

항목	값
Objective	binary
Early stopping metric	average_precision(PR-AUC)
Best iteration	312
Random seed	42
범주형 피처	city, registered_via, gender
원천 테이블	model_table_enhanced_v2.csv

14. 재현성과 추론 절차

모델·메타데이터·피쳐 순서를 함께 검증

제공 산출물

파일	역할
models/lightgbm_enhanced_v2.txt	312개 트리를 포함한 최종 LightGBM 모델
models/lightgbm_enhanced_v2_meta.json	57개 피쳐 순서, 범주형, 파라미터, 임계값, 평가값
models/lightgbm_enhanced_v2_importance.csv	57개 피쳐의 gain-split 중요도
train.py	동일 split·피쳐·파라미터를 사용한 안전한 재학습
infer.py	모델 로드, 입력 검증, 샘플 5건 확률·클래스 출력
requirements.txt	ML·백엔드 패키지 버전
requirements-extra.txt	PyTorch·생존분석 추가 패키지

실행 명령

PowerShell

```
python -m venv My_venv
My_venv\Scripts\Activate.ps1
python -m pip install -r requirements.txt
python train.py
python infer.py --rows 5
```

- 추론 시 모델의 feature_names와 메타데이터 feature_cols 순서가 같은지 검사합니다.
- LightGBM 모델에 저장된 범주 순서를 입력 DataFrame에 동일하게 적용합니다.
- 확률이 0.270839 이상이면 predicted_churn=1로 출력합니다.

15. 한계와 개선 방향

현재 결과의 적용 범위와 다음 단계

구분	현재 한계	개선 방향
시간 일반화	단일 2월 만료 코호트의 랜덤 분할	train_v2를 미래 코호트로 사용한 시간 외 검증
동적 행동	사용자별 집계형 정적 피쳐	주·월별 시퀀스와 생존·시계열 모델 비교
캠페인 효과	발송 기록만 있고 전환 이벤트 미수집	클릭·갱신·증분매출 수집 후 온라인 실험
비용 최적화	F1 및 Top-K 중심	고객가치·전환율·캠페인 비용 기반 기대효익 최적화
확률 보정	순위 성능 중심	Platt-Isotonic calibration 및 기간별 안정성 감시
딥러닝	정형 집계 피쳐 기반 MLP	원시 로그 시퀀스 모델 또는 임베딩 기반 구조 비교

최종 결론

LightGBM Enhanced v2는 Test PR-AUC 0.583427과 상위 5% Lift 9.55배를 달성했습니다. 예측 확률·고객 가치·구독 생명주기를 결합하면 Retention, 긴급 갱신, Win-back 캠페인의 우선순위 도구로 활용할 수 있습니다.

본 결과는 2017-01-31 관측 스냅샷에 대한 오프라인 검증 결과이며, 실제 운영 성과를 의미하지 않습니다.