

KKBOX 구독 이탈 예측 데이터 전처리 과정

원본 데이터를 모델이 이해할 수 있는 고객별 테이블로 만드는 과정

대상 고객

992,931명

이탈 라벨 보유

기본 모델 테이블

44열

결측치 0건

최종 고도화 테이블

61열

입력 피처 57개

근거: preprocessing/ 01~08 노트북의 저장된 실행 결과

01. 전처리의 목표: "고객 1명 = 데이터 1행"

여러 원본 파일을 고객 번호(msno)로 묶어 이탈 예측용 표를 만듭니다.

회원 정보

members_v3.csv
도시 · 성별 · 가입일

결제 이력

transactions.csv
플랜 · 자동갱신 · 금액

이용 로그

user_logs.csv
재생 · 이용시간 · 최근

이탈 라벨

train.csv
이탈 여부

↓ 고객 번호(msno) 기준으로 결합

모델 입력 테이블

고객 1명당 결제·이용 행동·회원 속성·이탈 라벨을 한 줄에 정리

- 핵심 원칙

모델에 들어가는 모든 정보는 이탈 여부를 확인하기 전인 2017-01-31까지의 기록만 사용

02. 먼저 고객을 Train / Validation / Test로 나눕니다

학습·검증·최종 평가에 같은 고객이 섞이지 않도록 분할

Train

695,051명

모델 학습 70%

Validation

148,940명

모델 선택 15%

Test

148,940명

최종 평가 15%

왜 이렇게 나누나요?

모델이 학습 때 본 고객을 시험에서 다시 맞히면 실제 성능보다 좋아 보일 수 있습니다.
그래서 고객 번호 기준으로 완전히 분리했고, 세 집합 간 고객 중복 0명을 확인했습니다.

- 이탈 비율 유지
세 집합 모두 이탈률 약 6.39%가 되도록 층화 분할 - 비교의 공정성 확보
- 관측 시점 고정
snapshot은 모든 고객에게 2017-01-31 - 이후 기록은 사용하지 않음

03. 원본 파일을 고객 행동 피처로 요약합니다

거래·로그처럼 여러 줄인 기록을 고객별 숫자로 압축

회원 정보

features_members

6.77M명

도시 · 가입경로 · 나이 · 성별 · 가입기간

고객별 1행으로 집계

거래 이력

features_transactions

2.33M명

거래 횟수 · 자동갱신 · 결제금액 · 최근 결제

고객별 1행으로 집계

이용 로그

features_user_logs

5.11M명

7/30/90일 활동일수 · 이용시간 · 완곡 재생

고객별 1행으로 집계


예시

“이 고객은 최근 30일 동안 며칠 접속했는가?”와 “자동갱신을 사용했는가?”처럼
원본의 여러 기록을 모델이 비교할 수 있는 숫자와 범주로 바꿉니다.

04. 이상치와 결측은 “정보를 버리지 않고” 표시합니다

값이 없다는 사실도 고객 상태를 설명할 수 있으므로 플래그를 함께 만듭니다.

병합 후 원본이 없는 고객 비율



처리 방식

- 나이
0 이하 또는 100 초과는 결측으로 처리하고 `bd_is_missing` 플래그 추가
- 성별
비어 있는 성별은 `unknown` 범주로 보존
- 기록 없음
`has_member_record` / `has_transaction_record` / `has_log_activity` 플래그로
- 날짜 이상치
비현실적 만료일은 결측 처리 후 이후 단계에서 중앙값으로 채움

병합 단계 결과: 992,931명 × 41열. 이후 결측 처리 플래그 3개가 추가됩니다.

05. 결측치는 Train 데이터의 중앙값으로 채웁니다

학습용 고객에서 계산한 대표값을 Validation·Test에도 동일하게 적용

중앙값으로 채우는 이유

극단적인 고객 한두 명의 영향이 평균보다 작아, "전형적인 고객" 값을 안전하게 대표합니다.

중요: 대표값은 Train에서만 계산 - Test 고객의 정보를 미리 보지 않습니다.

나이

28세

최근 결제 후 경과일

14일

최근 플랜 기간

30일

자동갱신 비율

1.0

30일 이용시간


5,010초

● 결과

model_table_final.csv: 992,931명 × 44열, 전체 결측치 0건

06. 마지막 고도화: "최근 마지막 이용일"을 추가합니다

이탈 직전의 이용 공백을 직접 측정하는 `days_since_last_log` 피처 생성



고도화 테이블: 992,931명 × 61열. 식별자·라벨·분할 컬럼을 제외한 모델 입력 피처는 57개입니다.

07. 최종 검증: 모델에 넣어도 되는 데이터인가?

크기·중복·결측·시간 기준·분할을 마지막으로 점검

행 수

992,931

대상 고객과 일치

고객 중복

0건

고객 1명 = 1행

결측치

0건

모든 피처 입력 가능

관측 기준일

2017-01-31

미래 정보 사용 안 함

분할

70 / 15 / 15

이탈률 균형 유지

한 문장으로 정리

전처리는 여러 원본 기록을, 누수 없이 고객별 한 줄의 신뢰할 수 있는 모델 입력 데이터로 바꾸는 과정입니다.