

KKBOX 구독 이탈 예측 모델 비교와 리텐션 해석

머신러닝 · 딥러닝 성능 비교, 위험도 세그먼트, SHAP 기반 실행 전략

최종 모델

LightGBM v2

57개 피처

Test PR-AUC

0.5834

불균형 데이터 핵심 지표

고위험 기준


0.2708

이탈 확률 threshold

근거: modeling/, dl_modeling/, analytics/ 노트북의 저장된 실행 출력

01. 모델링 접근: 표 형태의 고객 데이터를 예측 문제로 변환

사용자 단위 분할과 누수 방지 피처로 모델을 공정하게 비교



모델링 파이프라인




- 왜 PR-AUC인가?
이탈 고객이 6.39%라 Accuracy는 과대평가될 수 있어, 양성(이탈) 선별 성능을 더 잘 반영하는 PR-AUC를 주요 지표로 사용
- 테스트셋 원칙
최종 모델 선택 전에는 Validation으로 비교하고, Test 결과를 확인한 뒤 추가 튜닝하지 않음

02. 머신러닝 모델 간 비교

Validation PR-AUC 기준: 트리 기반 부스팅 모델이 우세

Validation PR-AUC



해석

- LightGBM 채택
가장 높은 PR-AUC와 빠른 학습, SHAP 해석·서
- 부스팅 계열
XGBoost·CatBoost도 0.56대 PR-AUC로 근소한
- 선형 모델 한계
복잡한 결제·로그 상호작용을 충분히 포착하지


노트북의 비교 기록을 기준으로 정리. 모델별 전처리·초기화 차이가 있으므로 절대값보다 순위와 경향을 해석합니다.

비교 결과는 modeling/03_model_comparison.ipynb 및 Optuna 노트북의 저장된 Validation 출력값에 근거합니다.

03. 피처 고도화: LightGBM 성능 개선 경로

행동 변화·결제 패턴·로그 최근성을 추가해 최종 모델을 완성

Validation PR-AUC 개선



최종 Test 성능

PR-AUC 0.5834

ROC-AUC 0.9036 · F1 0.5567

- Enhanced v1
활동 변화량, 결제 패턴, 만료일 정합성 파생변수로 PR-AUC +0.0090 (Baseline 대비 Validation)
- Enhanced v2
최근 이용 로그(days_since_last_log) 피처를 더해 v1보다 PR-AUC +0.0014, 최종 채택

04. 머신러닝과 딥러닝 비교

동일 문제에서 트리 기반 LightGBM이 MLP보다 높은 이탈 고객 선별 성능

Test PR-AUC



왜 LightGBM이 더 적합했나?

- 구조화된 표 데이터에 강함
- 결측·범주형·비선형 상호작용 처리
- SHAP으로 고객 행동 요인 설명 가능
- MLP는 68개 입력, 17,537개 파라미터로 학습했지만 성능 차이를 뒤집지 못함

MLP tuned Test: ROC-AUC 0.8924, PR-AUC 0.5599, F1 0.5438. LightGBM v2 대비 PR-AUC 차이: +0.0235.

05. 위험도 세그먼트: 고위험/저위험 분류

LightGBM의 고객별 이탈 확률을 threshold 0.2708 기준으로 구분

LightGBM 이탈 확률

threshold = 0.2708

확률 $\geq$ 기준: 고위험 / 미만: 저위험

고위험
10,256명

저위험
138,684명

Test 세그먼트(148,940명) - LTV 분석 노트북 집계

위험도 × 월매출 세그먼트

저위험
저월매출
69,559명

저위험
고월매출
69,125명

고위험
저월매출
4,639명


고위험
고월매출
5,617명

- 세그먼트 활용
위험도에 월매출(LTV 근사치)을 결합해 고객 우선순위와 차등 혜택을 결정합니다.

06. SHAP: 어떤 피처가 이탈 확률을 설명하는가?

Test 148,940명 중 5,000명 샘플로 계산한 평균 절대 SHAP 값

평균 |SHAP value|



핵심


자동갱신
신호가
가장 큼

※ 중요도는
인과관계가
아님

07. 위험도 세그먼트별 리텐션 전략: 실제 프론트엔드 구현


분석 결과를 고객 화면의 맞춤 혜택·결제·음악 추천 경험으로 연결

고위험 고객의 SHAP 세부 동인



자동갱신·만료·최근 이용 신호를 리마인드와 혜택 노출 타이밍에 반영

세그먼트별 실행 전략



프론트엔드 COUPON_RULES, BenefitsTab, BillingTab 구현을 기준으로 정리했습니다. 혜택 수령·발송 이력은 customer_actions에 기록됩니다.

08. 결론: 예측 → 세그먼트 → 실행

최종 모델의 역할은 고객을 낙인찍는 것이 아니라 대응 우선순위를 만드는 것

1. 예측

LightGBM v2가 Test PR-AUC 0.5834로 최종 채택

2. 분류

확률 0.2708을 기준으로 고위험/저위험 세그먼트 생성

3. 설명

SHAP으로 자동갱신·플랜·최근 이용·만료 상태의 영향 확인

4. 실행

고위험·고월매출 고객부터 갱신/혜택/재방문 캠페인 우선 적용

발표 마무리 메시지

“좋은 모델”의 기준은 AUC만이 아니라, 설명 가능한 고객 우선순위와 실행 가능한 리텐션 액션입니다.